

○ orthogonal Vectors

def: A set of nonzero vectors S is orthogonal

$$x, y \in S, x \neq y \Rightarrow x^T y = 0$$

Theorem: orthogonal なベクトル集合は線形独立

もし線形従属なら、

$$v_k = \sum_{\substack{i=1 \\ i \neq k}}^n c_i v_i \quad (v_1, v_2, \dots, v_n \in S)$$

$$v_k \neq 0, \|v_k\|^2 > 0 \text{ かつ}$$

$$v_k^T v_k = v_k^T \left(\sum_{\substack{i=1 \\ i \neq k}}^n c_i v_i \right) = \sum_{\substack{i=1 \\ i \neq k}}^n c_i v_k^T v_i = 0$$



○ Component of Vectors

$$r = v - (b_1^T v) b_1 - \dots - (b_n^T v) b_n \quad i=1, \dots, n.$$

r は直交か?

$$\begin{aligned} b_i^T r &= b_i^T v - (b_1^T v)(b_i^T b_1) - \dots - (b_n^T v)(b_i^T b_n) \\ &= b_i^T v - (b_i^T v)(b_i^T b_i) \\ &= 0 \end{aligned}$$

$\Rightarrow$ 残る r は既出の $b_1, \dots, b_n$ と直交する方向となる。



○ Vector Norms

def: p -norm (closed unit ball $\rightarrow \{x \in \mathbb{C}^m, \|x\| \leq 1\}$)

$$x, y \in \mathbb{R}^2$$

$$\|x\|_1 = \sum_{i=1}^m |x_i| \quad \rightarrow \quad x + y \leq 1$$

$$\|x\|_2 = \left(\sum_{i=1}^m |x_i|^2 \right)^{\frac{1}{2}} \quad \rightarrow \quad \sqrt{x^2 + y^2} \leq 1$$

$$\|x\|_\infty = \max_{1 \leq i \leq m} |x_i|$$

$$\|x\|_p = \left(\sum_{i=1}^m |x_i|^p \right)^{\frac{1}{p}}$$

1-norm は 郵便の 縦 + 横 + 高さ で使われている。

2-norm は Euclidean length

• weighted p -norm

ベクトル空間の各座標にはそれぞれ独自の重みを与えられる。

$$\|x\|_w = \|Wx\|$$




W は対角行列

$$\left\| \begin{bmatrix} w_1 & \\ & w_2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \right\| = \|w_1 x_1 + w_2 x_2\|$$

例 2-norm だと

$$\begin{aligned} \|x\|_w &= \left(\sum_{i=1}^m |w_i x_i|^2 \right)^{\frac{1}{2}} \quad (w_1 = 2, w_2 = 1) \\ &= \sqrt{4x^2 + y^2} \leq 1 \end{aligned}$$



* 一般的には W は 正則行列 だよ OK! (diag じゃなく...))

○ Matrix Norms Induced by Vector Norms

・誘導行列ノルム (induced matrix norms)

$m \times n$ 要素はそれぞれ独立な座標なので、

$m \times n$ 行列を $m \times n$ 次元空間とみなせる。

→ 行列のような"サイズ"の測かぎりに、 $m \times n$ 次元ノルムが使われる。

行列の空間を扱う際、 p -norm よりも有用な特別なノルムがある。

$\|\cdot\|_{(n)}$ と $\|\cdot\|_{(m)}$ をそれぞれ $A \in \mathbb{C}^{m \times n}$ の定義域と値域のノルムとす。

def $\|Ax\|_{(m)} \leq C \|x\|_{(n)}$

← $y = Ax \in \mathbb{R}^m$ i.e. $\mathbb{R}^n \xrightarrow{A} \mathbb{R}^m$

これを満たす最小の定数 C を $\|A\|_{(m,n)}$ とす。

→ $\frac{\|Ax\|_{(m)}}{\|x\|_{(n)}}$ の上界 ← A がベクトルを「伸ばす」最大倍率



$\|A\|_{(m,n)} = \sup_{\substack{x \in \mathbb{C}^n \\ x \neq 0}} \frac{\|Ax\|_{(m)}}{\|x\|_{(n)}}$

○ Examples

例 1


$A = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix}$

$Ae_1 = e_1, Ae_2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$



例2

対角行列は $|d_i|$ がそれぞれの軸の長さとなる。



つまり, $\|D\|_p = \max_{1 \leq i \leq n} |d_i|$

例3 行列の 1-norm

$$\|x\|_1 = \sum_{j=1}^n |x_j|$$

$$\|Ax\|_1 = \sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right|$$

三角不等式より,

$$\sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{i=1}^m \sum_{j=1}^n |a_{ij} x_j| = \sum_{j=1}^n \left(\sum_{i=1}^m |a_{ij}| \right) |x_j|$$

$$\sup \frac{\|Ax\|_1}{\|x\|_1} = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| = \max_{1 \leq j \leq n} \|a_j\|_1$$

例4 行列の ∞ -norm

$$\|x\|_\infty = \max_{1 \leq j \leq n} |x_j|$$

$$\|Ax\|_\infty = \max_{1 \leq i \leq m} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq m} \left(\sum_{j=1}^n |a_{ij}| \right) |x_j|$$

$$\sup \frac{\|Ax\|_\infty}{\|x\|_\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| = \max_{1 \leq i \leq m} \|a_i^*\|_1$$

Cauchy-Schwarz and Hölder Inequalities

$p=1, \infty$ はシンプルだったが、それ以下では計算が大変

任意のベクトル x, y で

$$|x^* y| \leq \|x\|_p \|y\|_q \quad \left(\frac{1}{p} + \frac{1}{q} = 1, 1 \leq p, q \leq \infty \right)$$

が成り立つ. ($p=q=2$ のとき, Cauchy-Schwarz)

◦ outer product

$A = uv^*$ と表現したとき.

$$\|Ax\|_2 = \|uv^*x\|_2 = \|u\|_2 |v^*x| \leq \|u\|_2 \|v\|_2 \|x\|_2$$

よって

$$\|A\|_2 \leq \|u\|_2 \|v\|_2$$

◦ $\|AB\|$ の Induced norm

$$A \in \mathbb{R}^{l \times m}, B \in \mathbb{R}^{m \times n}, x \in \mathbb{R}^n$$

$$\|ABx\|_{(l)} \leq \|A\|_{(l,m)} \|Bx\|_{(m)} \leq \|A\|_{(l,m)} \|B\|_{(m,n)} \|x\|_{(n)}$$

$$\therefore \|AB\|_{(l,n)} = \|A\|_{(l,m)} \|B\|_{(m,n)}$$

◎ General Matrix norm

ベクトルノルムであり、誘導ノルムでない。

Hilbert-Schmidt or Frobenius norm

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^m |a_{ij}|^2 \right)^{\frac{1}{2}} = \left(\sum_{j=1}^m \|a_j\|_2^2 \right)^{\frac{1}{2}}$$

$$\begin{aligned} (A^*A)_{ij} &= \sum_k a_{ik}^* a_{kj} \\ &= \sum_k a_{ki} a_{kj} \end{aligned}$$

$$\text{tr}(A^*A) = \sum_{i,j} \left(\sum_k a_{ki} a_{kj} \right) \leftarrow \text{全ての要素の2乗和}$$

$$\rightarrow \|A\|_F = \sqrt{\text{tr}(A^*A)} = \sqrt{\text{tr}(AA^*)}$$

$$\begin{aligned} \|AB\|_F^2 &= \sum_{i=1}^n \sum_{j=1}^m (a_i^* b_j)^2 \geq \sum_{i=1}^n \sum_{j=1}^m (\|a_i\|_2 \|b_j\|_2)^2 \\ &= \sum_{i=1}^n \|a_i\|_2^2 \cdot \sum_{j=1}^m \|b_j\|_2^2 \\ &= \|A\|_F^2 \|B\|_F^2 \end{aligned}$$

$$\|Qx\|_2^2 = (Qx)^T(Qx) = \|x\|_2^2 \quad \therefore \|Qx\|_2 = \|x\|_2$$

$$\|Qx\|_F^2 = \sqrt{(Qx)^*(Qx)} = \sqrt{x^*x} = \|x\|_F \quad \therefore \|Qx\|_F = \|x\|_F$$

① A Geometric Observation

σ_i, u_i は hyperellipse の軸となる。




Figure 4.1. SVD of a 2×2 matrix.

$$N \text{ に } A \text{ を施す} \\ \rightarrow AN = U\Sigma$$

$$\| \sigma_i u_i \| = \sigma_i (>0)$$

- AS の n 個の特異値
→ hyperellipse の半軸の長さ
- A の n 個の左特異ベクトル u_i
→ hyperellipse の主半軸方向を指すベクトル。
- A の n 個の右特異ベクトル v_i
→ A の主半軸

V^T が単位円,
 Σ で拡大, 縮小
 U で回転

② Reduced SVD = Full SVD

$\text{rank}(A) = n$ の場合

$$\boxed{A}_{m \times n} = \boxed{\hat{U}}_{m \times n} \boxed{\hat{\Sigma}}_{n \times n} \boxed{V^T}_{n \times n}$$

← reduced

$\hat{U}$ は orthogonal だが正方形ではないのでユニタリ行列ではない。

⇒ $\hat{U}$ に対して $m-n$ 列を追加して正方形にする。

$$\boxed{A}_{m \times n} = \boxed{U}_{m \times m} \boxed{\Sigma}_{m \times n} \boxed{V^T}_{n \times n}$$

← full

A がランク落ちして $\text{rank}(A) = r$ としても $m-r$ 列を追加して同じ形

このときの $\hat{\Sigma}$ の対角

$A \in \mathbb{R}^{m \times n}$ かつ、 $\text{rank}(A) = r$ ($r \leq n$) の場合、

reduced SVD の $\hat{\Sigma}$ の対角要素はゼロを含まない。

縮退して $\hat{\Sigma} \in \mathbb{R}^{r \times r}$ とした reduced SVD とした場合、

対角要素は厳密に正である。

④ 存在と一意性 (Existence and Uniqueness)

定理

- 全ての行列において特異値分解が可能。
- 特異値は一意。
- A が正方で σ が相異なる場合、

v, u は複素の符号を除き一意

証明

A の作用が最大となる方向の v を取り出し、 A の次元の帰納法を行う。

まず $\sigma_1 = \|A\|_2$ としたとき、 $Av_1 = \sigma_1 u_1$ を満たす v_1, u_1 の存在を示す。

$\|A\|_2 = \sup_{\|v\|=1} \|Av\|_2$ が成り立つが、 $\sup$ なので、達成される (つまり $\max$)
かどうかは保証されていない。

→ 最大値をとる v_1 の存在を示す。

定義域: $v \in S, \|v\|=1$

関数: $f(v) = \|Av\|_2$

S は単位球面上に納まり、有界で閉なので S はコンパクト集合。

Heine - Borel の定理

コンパクト集合上の連続関数は最大値を達成する。

↳ Weierstrass の最大値定理

f は S 上の連続関数なので f を最大化する v_1 が存在する。

—+

以上より $Av_1 = \sigma_1 u_1$ が成立する。

$v \in \mathbb{C}^n$, $u \in \mathbb{C}^m$ より、それぞれ $n-1, m-1$ 個の正規直交基底を追加。

$$AV_1 = [A'v_1, A'v_2, \dots, A'v_n]$$

$$U_1^* AV_1 = \begin{bmatrix} -u_1^* & - \\ -u_2^* & - \\ \vdots & - \\ -u_m^* & - \end{bmatrix} [A'v_1, A'v_2, \dots, A'v_n]$$

$$= \begin{bmatrix} -u_1^* & - \\ -u_2^* & - \\ \vdots & - \\ -u_m^* & - \end{bmatrix} \begin{bmatrix} \sigma_1 u_1 & A'v_2 & \dots & A'v_n \end{bmatrix}$$

$$= \begin{bmatrix} \sigma_1 \|u_1\|^2 & u_1^* A'v_2 & \dots & u_1^* A'v_n \\ 0 & u_2^* A'v_2 & & \vdots \\ \vdots & \vdots & & \\ 0 & u_m^* A'v_2 & \dots & u_m^* A'v_n \end{bmatrix}$$

$$= \begin{bmatrix} \sigma_1 & w^* \\ 0 & B \end{bmatrix}$$

$z = z'$

$$\left\| \begin{bmatrix} \sigma_1 & w^* \\ 0 & B \end{bmatrix} \begin{bmatrix} \sigma_1 \\ w \end{bmatrix} \right\|_2 \geq \sigma_1^2 + w^* w = (\sigma_1^2 + w^* w)^{\frac{1}{2}} \left\| \begin{bmatrix} \sigma_1 \\ w \end{bmatrix} \right\|_2$$

$$\therefore \|U_1^* AV_1\|_2 \geq (\sigma_1^2 + w^* w)^{\frac{1}{2}}$$

U_1^*, V_1 は $z = z'$ より

$$\|U_1^* AV_1\|_2 = \|A\|_2 = \sigma_1$$

$$\Leftrightarrow \sigma_1 \geq (\sigma_1^2 + w^* w)^{\frac{1}{2}} \therefore w = 0$$

帰納的に $B = U_2 \Sigma_2 V_2^*$ とする。

$$U_1^* A V = \begin{bmatrix} \sigma_1 & 0 \\ 0 & U_2 \Sigma_2 V_2^* \end{bmatrix} .$$

$$= \begin{bmatrix} 1 & U_2 \end{bmatrix} \begin{bmatrix} \sigma_1 & \\ & \Sigma_2 \end{bmatrix} \begin{bmatrix} 1 & V_2 \end{bmatrix}$$

$$A = U_1 \begin{bmatrix} 1 & U_2 \end{bmatrix} \begin{bmatrix} \sigma_1 & \\ & \Sigma_2 \end{bmatrix} \begin{bmatrix} 1 & V_2 \end{bmatrix} V_1^*$$

← SVD

○ 基底の変換

$b = Ax$ において、

$$b = U \Sigma V^* x$$

$$U^* b = \Sigma V^* x \quad \text{より} \quad b' = \Sigma x' \quad (b' = U^* b, x' = V^* x)$$

つまり

$b = Ax$ を解くとき、

$$\begin{cases} b' := U^* b & (\text{値域を } U \text{ の列の基底で表現}) \\ x' := V^* x & (\text{定義域を } V^* \text{ の列の基底で表現}) \end{cases}$$

$$\Rightarrow b' = \Sigma x' \quad (A \text{ は } \Sigma \text{ に簡約})$$

○ SVD と 固有値分解

nondefective な正定行列 (対角化可能な行列)

行列 X の列が A の線形独立な固有ベクトルからなるとき、

$$A = X \Lambda X^{-1}$$

同様に

$$X^{-1} b = \Lambda X^{-1} x \Rightarrow b' = \Lambda x' \quad (b' = X^{-1} b, x' = X^{-1} x)$$

SVD と 特異値分解の違い、

1. 特異値分解では SVD と異なり、1つの基底 (固有ベクトル) のみ
2. SVD の基底は正規直交基底だが、

固有値分解の基底は一般に直交しない。

3. すべての行列が固有値分解で表す訳ではない。

定理 5.1

$\text{rank}(A)$ は 非零特異値の個数と一致

証明

U, V はフルランクより、 $\text{rank}(A)$ は $\text{rank}(\Sigma)$ に依存する。

$$\text{rank}(A) = \text{rank}(\Sigma) = r \quad \square$$

定理 5.2

$$\text{range}(A) = \langle u_1, \dots, u_r \rangle \quad \text{かつ} \quad \text{null}(A) = \langle v_{r+1}, \dots, v_n \rangle$$

証明

$$\left(\begin{array}{l} \text{前提より. } A \in \mathbb{R}^{m \times n} \text{ は } \mathbb{R}^n \rightarrow \mathbb{R}^m \text{ の線形写像が } Ax = b \text{ により行われ,} \\ \text{サイズより } x \in \mathbb{R}^n \text{ ならば } Ax \in \mathbb{R}^m \text{ である.} \\ \text{range}(A) = \{ b \in \mathbb{R}^m \mid b = Ax, x \in \mathbb{R}^n \} \end{array} \right.$$

$$\Sigma e_j = \begin{cases} \sigma_j e_j & (j < r) \\ 0 & (j > r) \end{cases}$$

$$\text{range}(\Sigma) = \langle e_1, \dots, e_r \rangle$$

$$\text{null}(\Sigma) = \langle e_{r+1}, \dots, e_n \rangle$$

V は $\Sigma = U \Lambda V^T$ 行列なので.

$$x = c_1 u_1 + c_2 u_2 + \dots \text{ と表現できる.}$$

$$\text{このとき } c_1, c_2, \dots \text{ は}$$

「 x を V の基底で見たときの座標」という.

$$x = c_1 v_1 + c_2 v_2, \quad v_1^* x = c_1, \quad v_2^* x = c_2$$


$$V^* x = \begin{bmatrix} c_1 \\ \vdots \\ c_r \end{bmatrix} \quad \text{即ち} \quad \begin{bmatrix} c_1' \\ \vdots \\ c_r' \end{bmatrix}$$

$$\text{range}(A) = \langle u_1, \dots, u_r \rangle$$

$$U \Sigma V^* x = 0 \Leftrightarrow \Sigma V^* x = 0$$

$$\text{null}(A) = \langle v_{r+1}, \dots, v_n \rangle$$

基底変換



定理 5.4

$$\|A\|_2 = \sigma_1, \quad \|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}$$

証明

$$\|A\|_2 = \|U\|_2 \|\Sigma\|_2 \|V^*\|_2 = \|\Sigma\|_2 = \sigma_1 \quad \checkmark$$

$$\begin{aligned} \|A\|_F &= \|U\|_F \|\Sigma\|_F \|V^*\|_F = \|\Sigma\|_F = \sqrt{\Sigma^* \Sigma} \\ &= \sqrt{\sigma_1^2 + \dots + \sigma_r^2} \quad \checkmark \end{aligned}$$

定理 5.5

$A = A^*$ の特異値は固有値の絶対値要素

証

$$\begin{aligned} A &= Q \Lambda Q^* \\ &= Q |\Lambda| \text{sign}(\Lambda) Q^* \\ &= U \Sigma V^* \end{aligned}$$

定理 5.6

$$|\det(A)| = \prod_{i=1}^n \sigma_i \quad (A \in \mathbb{R}^{n \times n})$$

© Low-Rank Approximation.